Đánh giá lại CIRAG trên Hỏi đáp Đa bước tiếng Việt: điều kiện dừng theo câu từ chối và một phép kiểm thay thế trên bằng chứng

Tan Nguyen Dang Duy, Huy Tran Anh, Tien Le Van, and Tram Nguyen Hong
Faculty of Information Technology
University of Science, VNU-HCM
Ho Chi Minh City, Vietnam
{25C1502208, 25C1100780, 25C1106995, 25C1107056}@student.hcmus.edu.vn

Tóm tắt nội dung

CIRAG (Wei et al., 2026) nén các đoạn văn đã truy hồi thành triple (s, r, o) để bớt nhiễu, và các tác giả báo cáo mức cải thiện lớn so với những phương pháp truy hồi lặp trước đó. Chúng tôi cài đặt lại phương pháp này, rồi chạy thử trên chính bộ dữ liệu và mô hình nền mà bài báo gốc dùng. Bản cài đặt tái lập được khoảng cách họ công bố trong phạm vi 0,6 điểm EM. Nhưng khi chúng tôi chuyển sang ViMQA (Le et al., 2022), bộ hỏi đáp đa bước tiếng Việt, khoảng cách đó biến mất. Bốn thí nghiệm có kiểm soát cho thấy nguyên nhân không nằm ở bản cài đặt, prompt tiếng Việt, một khâu trong pipeline chạy sai hay năng lực mô hình nền. Nguyên nhân nằm ở điều kiện dừng của phương pháp. ACMG chỉ mở rộng ngữ cảnh khi mô hình tự nói ra rằng nó không trả lời được, nghĩa là nó tin vào phán đoán của mô hình thay vì tự kiểm tra ngữ cảnh. Mô hình nền càng mạnh thì càng ít khi nói vậy, nên hệ thống hầu như luôn dừng ở mức ngữ cảnh hẹp nhất và trả lời sai từ đó. Chúng tôi thay điều kiện đó bằng một phép kiểm đặt trên chính bằng chứng. Phép kiểm này đòi tập triple lõi phải đến từ đủ số tài liệu mà câu hỏi đa bước cần, và nó nâng EM từ 50,80 lên 60,40 mà không tốn thêm lời gọi mô hình nào.

1 Giới thiệu

Sinh có tăng cường truy hồi (Lewis et al., 2020) hoạt động tốt với câu hỏi đơn giản nhưng gặp khó ở suy luận đa bước, vì truy hồi một lượt không gom được các bằng chứng liên kết với nhau. Truy hồi lặp (Trivedi et al., 2023) giảm bớt khó khăn này bằng cách chia thành nhiều lượt, mỗi lượt dùng thông tin vừa thu được để tạo truy vấn tiếp theo. Gần đây, một số công trình thay đoạn văn bằng triple làm đơn vị truy hồi (Fang et al., 2024, 2025) nhằm thu hẹp phạm vi bằng chứng và giảm nhiễu.

CIRAG (Wei et al., 2026) nhắm vào hai vấn đề riêng biệt của hướng truy hồi lặp trên triple. Vấn đề thứ nhất là mở rộng tham lam theo một đường. Các phương pháp trước chỉ giữ một triple tốt nhất ở mỗi bước, nên sai sót ở bước đầu lan sang các bước sau, đồng thời những nhánh bằng chứng song song cần cho câu hỏi phức tạp bị bỏ qua. Vấn đề thứ hai nằm ở mức ngữ cảnh: triple có cấu trúc rõ và ít nhiễu nhưng thiếu ngữ cảnh, còn đoạn văn đủ ngữ cảnh nhưng nhiều nhiễu, nên không có mức cố định nào phục vụ được mọi câu hỏi.

Nhằm hạn chế mở rộng tham lam, CIRAG đề xuất module truy hồi ICI (Iterative Construction-Integration), xây dựng trên mô hình Kiến tạo và Tích hợp trong tâm lý học nhận thức (Kintsch and Van Dijk, 1978). Giai đoạn kiến tạo gom triple của các đoạn vừa truy hồi thành một tập ứng viên rộng, giai đoạn tích hợp để mô hình nền chọn ra tập triple lõi thực sự cần cho câu hỏi rồi sinh truy vấn kế tiếp. Vì được phép chọn nhiều triple cùng lúc, tập lõi có thể chứa bằng chứng của nhiều nhánh suy luận khác nhau thay vì chỉ một nhánh.

Nhằm khớp mức ngữ cảnh với nhu cầu của câu hỏi, CIRAG đề xuất module sinh ACMG (Adaptive Cascaded Multi-Granularity Knowledge-Enhanced Generation). Ở mỗi mức, hệ thống đưa cho mô hình phần ngữ cảnh của mức đó và yêu cầu trả lời, kèm chỉ dẫn rằng nếu ngữ cảnh chưa đủ thì phải trả về một câu từ chối định sẵn thay vì đoán. Chính câu từ chối đó là tín hiệu để mở rộng ngữ cảnh. Module bắt đầu ở mức triple, và chỉ chuyển sang mức câu rồi mức đoạn văn khi nhận được câu từ chối.

Chúng tôi cài đặt lại CIRAG và đánh giá trên ViMQA (Le et al., 2022), bộ hỏi đáp đa bước tiếng Việt. Bản cài đặt tái lập được lợi thế mà bài báo gốc công bố khi chạy trên chính bộ dữ liệu của họ, nhưng lợi thế đó không xuất hiện trên ViMQA, và phần còn lại của báo cáo đi tìm lý do. Đóng góp gồm bốn điểm:

- Chúng tôi kiểm chứng bản cài đặt trên 2WikiMultihopQA với đúng mô hình nền mà bài báo gốc dùng. Khoảng cách giữa CIRAG và IRCoT đo được chỉ lệch 0,6 điểm EM so với

con số họ công bố (§6).

- CIRAG dựa vào câu từ chối của mô hình để biết ngữ cảnh đã đủ hay chưa. Dấu hiệu này sai theo cả hai chiều: mô hình từ chối cả khi bằng chứng đã có sẵn, và trả lời cả khi bằng chứng còn thiếu (§7).
- Chúng tôi thay dấu hiệu đó bằng một phép kiểm trên chính bằng chứng. Câu hỏi đa bước cần dữ kiện từ ít nhất hai tài liệu, nên hệ thống chỉ dừng khi tập triple lõi đã đến từ đủ hai tài liệu. Phép kiểm nâng EM từ 50,80 lên 60,40 mà không tốn thêm lời gọi mô hình nào (§8).
- Chúng tôi loại trừ bốn cách giải thích khác cho việc lợi thế của CIRAG không xuất hiện trên ViMQA: lỗi cài đặt, prompt tiếng Việt, một khâu trong pipeline chạy sai, và năng lực mô hình nền (§9).

2 Công trình liên quan

Truy hồi lặp trên văn bản. IRCoT (Trivedi et al., 2023) xen kẽ sinh chuỗi suy luận với truy hồi, dùng câu suy luận vừa sinh làm truy vấn kế tiếp. Self-Ask (Press et al., 2023) phân rã câu hỏi thành các câu hỏi con tường minh. Vì mỗi lượt đưa thêm nguyên đoạn văn vào ngữ cảnh, nhiễu tích tụ dần qua các vòng.

Truy hồi lặp trên triple. Để giảm nhiễu đó, một nhánh nghiên cứu đổi đơn vị truy hồi từ đoạn văn sang triple. HippoRAG (Jimenez Gutierrez et al., 2024) dựng đồ thị tri thức từ triple trích được, còn KiRAG (Fang et al., 2025) nối dần các triple thành một chuỗi bằng chứng qua từng vòng lặp. Đổi lại, chúng chỉ giữ một triple tốt nhất ở mỗi bước và cố định biểu diễn ở mức triple.

CIRAG khác hai nhánh trên ở đúng hai điểm đó. Nó giữ một tập triple lõi thay vì một chuỗi đơn, và mở rộng ngữ cảnh theo bậc thay vì cố định ở một mức.

3 Phương pháp

CIRAG chạy hai module nối tiếp (Hình 1): ICI truy hồi và lọc bằng chứng thành một tập triple lõi, còn ACMG sinh câu trả lời từ tập đó. Bài báo gốc còn một module thứ ba, Trajectory Distillation, huấn luyện một mô hình nhỏ bắt chước quỹ đạo suy luận của mô hình lớn để giảm chi phí. Chúng tôi không cài module này, nên mọi con số trong báo cáo đối chiếu với cấu hình *w/o TD* của bài báo gốc.

ICI. Mỗi vòng lặp gồm hai giai đoạn. Giai đoạn kiến tạo truy hồi top-K đoạn cho truy vấn q_t, gom triple của các đoạn đó rồi xếp hạng lấy top-N ứng viên. Giai đoạn tích hợp giao tập ứng viên cùng lịch sử $H_{<t}$ cho mô hình nền, để mô hình giữ lại tập triple lõi F_t và sinh truy vấn q_{t+1}. Vòng lặp dừng khi mô hình sinh `<no question>`, tối đa L vòng.

Mỗi triple đều lưu vết câu và đoạn đã sinh ra nó. Hai ánh xạ ngược này, ký hiệu M^S và M^D, cho phép từ F dựng ra tập câu $S = M^S(F)$ và tập đoạn $D = M^D(F)$. Ba tập F, S, D chính là ba mức ngữ cảnh mà ACMG sử dụng.

ACMG. Hệ thống lần lượt đưa F, rồi S, rồi D cho mô hình và yêu cầu trả lời. Nếu ngữ cảnh chưa đủ, mô hình phải trả về một câu từ chối định sẵn. Đáp án được lấy ở mức đầu tiên mà mô hình không từ chối:

$$g^\star = \min_{\prec}\{g \in G : \mathrm{Suf}(a^{(g)}) = 1\}, \quad a^\star = a^{(g^\star)} \tag{1}$$

trong đó $\mathrm{Suf}(a)$ nhận giá trị đúng khi a không thuộc mẫu từ chối. Nếu không có mức nào thoả, hệ thống lùi về câu trả lời mức tài liệu. Hai chi tiết ở đây quyết định phần sau của báo cáo: Suf chỉ quan sát câu trả lời chứ không quan sát ngữ cảnh, và cả ba mức đều dựng từ một tập F duy nhất. §7 cho thấy mỗi chi tiết dẫn tới một kiểu lỗi riêng.

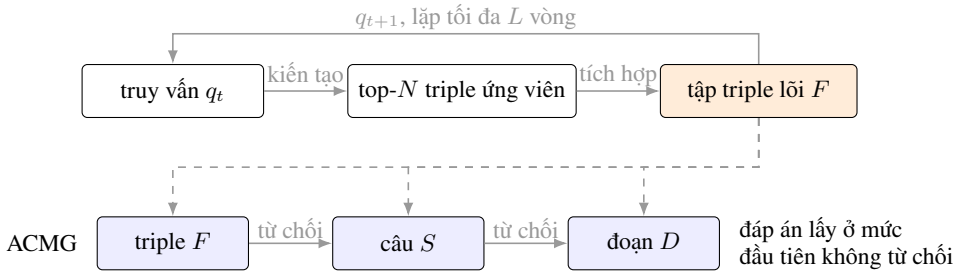
4 Dữ liệu

ViMQA (Le et al., 2022) là bộ hỏi đáp đa bước tiếng Việt do người viết ra từ các bài Wikipedia tiếng Việt, tổ chức theo cấu trúc HotpotQA (Yang et al., 2018). Mỗi câu hỏi kèm mười đoạn văn, trong đó hai đoạn chứa bằng chứng và tám đoạn gây nhiễu.

Chúng tôi lấy ngẫu nhiên 500 câu hỏi từ tập validation. Nếu mỗi câu hỏi chỉ tìm trong mười đoạn đi kèm nó thì hệ thống gần như luôn lấy đúng cả hai đoạn bằng chứng, và khâu truy hồi mất ý nghĩa. Theo cách làm của IRCoT, chúng tôi hợp nhất đoạn của mọi câu hỏi rồi khử trùng lặp theo tiêu đề, thu được một kho ngữ liệu dùng chung gồm 1.969 đoạn.

5 Thiết lập thực nghiệm

Siêu tham số giữ nguyên theo bài báo gốc (K=10, N=30, L=4). Chúng tôi thay hai thành phần cho phù hợp với tiếng Việt. Thứ nhất, embedding dùng Vietnamese_Embedding, đạt recall@10 bằng 0,920 trên kho 1.969 đoạn. Thứ hai, prompt trích triple



Hình 1: Quy trình CIRAG. ICI lặp giữa giai đoạn kiến tạo và giai đoạn tích hợp để thu tập triple lõi F. ACMG thử sinh câu trả lời trên F trước, chỉ leo sang mức câu rồi mức đoạn khi mô hình trả về câu từ chối. Mũi tên nét đứt cho thấy cả ba mức đều suy ra từ F, nên thiếu sót của giai đoạn tích hợp lan sang cả ba (§7.2).

viết lại bằng tiếng Việt, trích được 22.697 triple cho toàn kho. Mô hình suy luận là Gemini 2.5 Flash, còn khâu trích triple dùng bản Flash Lite.

Độ đo. Gọi $\hat{a}$ là câu trả lời của hệ thống, a là đáp án tham chiếu và $\nu(\cdot)$ là hàm chuẩn hoá. EM bằng 1 khi $\nu(\hat{a})$ và $\nu(a)$ là hai chuỗi giống hệt nhau, còn F1 là trung bình điều hoà của độ chính xác và độ phủ tính trên số token dùng chung. F1 không xét token nằm ở đâu, còn EM đòi đúng cả thứ tự.

Tiếng Việt buộc chúng tôi điều chỉnh ν ở hai điểm. Thứ nhất, cùng một chữ có dấu có thể lưu bằng hai chuỗi byte khác nhau mà hiển thị giống hệt nhau, nên ν quy mọi chuỗi về một dạng Unicode chuẩn trước khi so. Thứ hai, một từ tiếng Việt có thể gồm nhiều âm tiết (“học sinh” là một từ nhưng hai âm tiết), và F1 thay đổi theo cách tách nên chúng tôi báo cáo cả hai.

Kiểm định ý nghĩa thống kê. Hai phương pháp trả lời cùng một tập câu hỏi, nên phần lớn câu chúng cùng đúng hoặc cùng sai. Chỉ những câu một bên đúng còn bên kia sai mới phân biệt được hai phương pháp, và kiểm định McNemar chỉ đếm nhóm câu đó: nếu hai phương pháp ngang nhau thì số câu nghiêng về mỗi bên phải xấp xỉ bằng nhau. Giá trị p nhỏ nghĩa là chênh lệch quan sát được khó xảy ra do may rủi.

EM phạt cả câu trả lời đúng nội dung. EM chỉ cho điểm khi hai chuỗi giống hệt nhau, nên mọi chênh lệch độ dài giữa câu trả lời và đáp án tham chiếu đều thành điểm 0. Chênh lệch này xảy ra theo hai chiều. Chiều thứ nhất là đáp án tham chiếu dài: hệ thống nêu đủ các thành phần nhưng đảo thứ tự, cho F1 bằng 1,00 mà EM bằng 0, và trong 99 câu có đáp án dài hơn năm âm tiết chỉ 10 câu đạt EM bằng 1. Chiều này không xử lý được, nên nó đặt một trần lên mọi con số EM trong báo cáo. Chiều thứ hai là câu trả lời dài: mô hình đáp bằng câu hoàn chỉnh (“Đội tuyển vô địch 2 lần”) trong khi đáp án chỉ là cụm ngắn (“2”). Chiều này xử lý được bằng một bước rút gọn trước khi chấm.

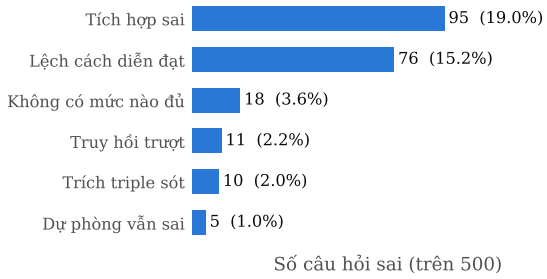
Phương pháp	**EM**	**F1**	**Δ**	p
2WikiMultihopQA, Qwen2.5-7B, 100 câu				
IRCoT (chúng tôi)	40,00	44,63		
CIRAG (chúng tôi)	54,00	57,97	**+14,0**	0,013
IRCoT (bài báo gốc)	36,4	45,7		
CIRAG *w/o TD* (gốc)	49,8	59,7	**+13,4**	
ViMQA, Gemini 2.5 Flash, 500 câu				
NativeRAG	55,20	67,95	−3,8	0,056
IRCoT	59,00	73,27		
CIRAG, điều kiện gốc	50,80	66,66	−8,2	<0,001
+ mức dự phòng	57,00	73,05	−2,0	0,29
+ điều kiện đủ mới	**60,40**	**75,08**	**+1,4**	0,44

Bảng 1: Cột Δ là chênh lệch EM so với IRCoT, cột p là kiểm định McNemar cho chênh lệch đó (bài báo gốc không công bố p). Ba dòng cuối là bản cài đặt của chúng tôi: điều kiện dừng gốc ở Phương trình 1, rồi cộng dồn hai thay đổi ở §8.

Những gì được giữ cố định. Chúng tôi so CIRAG với hai baseline: NativeRAG truy hồi một lượt rồi trả lời, còn IRCoT truy hồi lặp trên đoạn văn. Cả ba dùng chung module truy hồi, kho ngữ liệu và mô hình nền, nên khác biệt còn lại chỉ nằm ở cách mỗi phương pháp chọn bằng chứng và sinh câu trả lời. Bước rút gọn câu trả lời cũng chạy cho cả ba. Nếu chỉ CIRAG được rút gọn, con số đo được sẽ cho biết phương pháp nào trả lời ngắn gọn hơn chứ không phải phương pháp nào suy luận đúng hơn.

6 Kết quả

Bản cài đặt tái lập được bài báo gốc. Kết quả trên ViMQA chỉ có nghĩa nếu bản cài đặt đúng, nên trước hết chúng tôi chạy nó trên 2WikiMultihopQA với Qwen2.5-7B, đúng bộ dữ liệu và mô hình nền mà bài báo gốc dùng. CIRAG vượt IRCoT 14,0 điểm EM, so với 13,4 điểm bài báo gốc công bố (Bảng 1). Từng điểm số riêng lẻ lệch dưới 4,2 điểm



Hình 2: Phân loại 215 câu sai theo khâu phát sinh lỗi đầu tiên.

so với con số họ công bố. Sai lệch này là điều phải có, vì chúng tôi chạy 100 câu trên kho 770 đoạn nên truy hồi dễ hơn thiết lập của họ. Khoảng cách giữa hai phương pháp thì không chịu ảnh hưởng đó, vì cả hai chạy trên cùng một kho, và khoảng cách này chỉ lệch 0,6 điểm.

Lợi thế đó không xuất hiện trên ViMQA. NativeRAG, chỉ truy hồi một lượt, xếp dưới IRCoT 3,8 điểm EM. Khoảng cách này xác nhận ViMQA thật sự cần nhiều lượt truy hồi, nên đem hai phương pháp lặp ra so là có nghĩa. CIRAG xếp dưới IRCoT 2,0 điểm EM. Nhưng chỉ có 31 câu CIRAG đúng mà IRCoT sai, so với 41 câu ngược lại, nên khoảng cách này chưa đủ bằng chứng ($p = 0{,}29$). Số liệu vì vậy chỉ cho phép nói CIRAG *không còn hơn* IRCoT như trên 2WikiMQA, chứ chưa cho phép nói CIRAG *thua* IRCoT.

7 Phân tích lỗi

Hình 2 xếp 215 câu sai theo khâu phát sinh lỗi đầu tiên. Truy hồi và trích xuất triple cộng lại chỉ gây ra 21 câu, nên khâu thu thập bằng chứng không phải chỗ nghẽn. Chỗ nghẽn là giai đoạn tích hợp, nơi mô hình chọn tập triple lõi: riêng khâu này gây ra 95 câu. Thêm 76 câu nữa đúng nội dung nhưng bị EM cho điểm 0 vì lệch cách diễn đạt (§5), tức lỗi của độ đo chứ không phải của phương pháp.

7.1 Điều kiện dừng thoả quá sớm

Cơ chế cascade không mang lại lợi ích nào trong thiết lập của chúng tôi, thậm chí gây hại. Hai biến thể bỏ hẳn cascade, một luôn đọc mức câu và một luôn đọc mức đoạn, cho kết quả cao hơn cascade đầy đủ 3,8 và 4,2 điểm EM ($p < 0{,}005$), nên Bảng 2 đi ngược Table 3 của bài báo gốc.

Cũng chính Bảng 2 chỉ ra nguyên nhân. Biến thể luôn dùng mức triple đạt 57,40, gần như trùng với 57,00 của cascade đầy đủ. Hai cấu hình cho cùng kết quả nghĩa là cascade hầu như không mở rộng ngữ cảnh, mà dừng ở mức triple đúng 361/500 câu. Lý do nằm ở tín hiệu nó chờ: Suf chỉ cho phép mở rộng ngữ cảnh khi mô hình trả về câu từ chối, mà Gemini 2.5 Flash hiếm khi trả về.

Cấu hình	EM	F1
Cascade đầy đủ	57,00	73,05
chỉ mức triple	57,40	72,99
chỉ mức câu	60,80	**75,38**
chỉ mức đoạn	**61,20**	75,16
triple + câu	57,00	73,03
triple + đoạn	56,80	72,78
$L = 1$	52,60	67,52
$L = 2$	57,40	73,18

Bảng 2: Bóc tách thành phần. Mọi biến thể đều giữ mức dự phòng ở §8, nên các dòng so sánh được với nhau nhưng không so trực tiếp được với Table 3 của bài báo gốc. Hai dòng cuối cho thấy hiệu năng bão hoà từ L=2.

7.2 Mọi mức ngữ cảnh thừa hưởng thiếu sót của khâu lọc

Kiểu lỗi thứ hai là hệ thống từ chối trả lời dù bằng chứng đã nằm trong tay. Cả ba mức đều dựng từ một tập triple lõi, nên khâu lọc bỏ sót phần nào thì F, S và D cùng thiếu đúng phần đó, và mở rộng ngữ cảnh chỉ là đọc lại cùng một thiếu sót ở dạng dài hơn. Mô hình từ chối ở cả ba mức, và hệ thống rơi vào nhánh mặc định của Phương trình 1. Nhánh này nhận 73 câu, toàn bộ đều sai, nhưng 66 câu trong số đó có recall truy hồi bằng 1,0: module truy hồi đã lấy về đủ bằng chứng và chính khâu lọc đã loại đi. Nhóm chịu thiệt nặng nhất là câu hỏi so sánh hai thực thể, 24 trong 51 câu, vì khâu lọc thường chỉ giữ triple về một trong hai.

8 Thay điều kiện đủ bằng phép kiểm bằng chứng

Suf dùng câu từ chối làm dấu hiệu cho việc ngữ cảnh đã đủ hay chưa, và dấu hiệu này sai theo cả hai chiều: mô hình từ chối cả khi bằng chứng đã có sẵn (§7.2), và trả lời cả khi bằng chứng còn thiếu (§7.1). Chúng tôi sửa chiều thứ nhất trước, vì mức cải thiện của hai bản sửa cộng dồn lên nhau.

Mô hình từ chối dù bằng chứng đã có. Chúng tôi bổ sung một mức cuối không dựng từ tập lõi: khi không có mức nào trong cascade trả lời được, hệ thống đọc lại toàn bộ đoạn đã truy hồi. Mức này nâng EM từ 50,80 lên 57,00 và giảm số câu bị từ chối từ 73 xuống 35, với 31 trong 38 câu nó xử lý cho đáp án đúng.

Mô hình trả lời dù bằng chứng còn thiếu. Ở đây hệ thống chốt ngay mức triple với một câu trả lời trôi chảy nhưng sai, và đầu ra không có gì báo hiệu. Mô hình không bịa đáp án: trong 262 câu kiểm được bằng chuỗi, 252 câu có đáp án nằm nguyên trong tập triple lõi. Nó đọc đúng những triple nhận được, chỉ là tập triple đó chưa đủ.

Tập nào đủ và tập nào chưa thì đo được: mỗi triple đều lưu vết đoạn đã sinh ra nó, nên ánh xạ provenance M^D (§3) cho biết cả tập lõi đến từ bao nhiêu đoạn khác nhau. Nhóm mà cả tập lõi chỉ đến từ một đoạn đạt 35,7 EM, nhóm đến từ hai đoạn đạt 71,6. Vì mọi câu hỏi ViMQA đều cần bằng chứng từ ít nhất hai đoạn, tập lõi gói trong một đoạn là chưa đủ về mặt cấu trúc, bất kể mô hình có sẵn lòng trả lời hay không.

Chúng tôi vì vậy thêm một điều kiện trên bằng chứng bên cạnh điều kiện sẵn có trên câu trả lời:

$$\mathrm{Suf}'(a, F) = \mathrm{Suf}(a) \cdot \mathbf{1}\big[|M^D(F)| \geq h\big] \quad (2)$$

với h là số tài liệu câu hỏi đòi hỏi. Không thoả thì hệ thống bỏ qua các mức hẹp và đọc thẳng mức rộng nhất. Phép kiểm chỉ đọc lại thông tin có sẵn nên không tốn thêm lời gọi mô hình, và $h = 2$ suy từ cấu trúc bộ dữ liệu chứ không dò trên tập đánh giá.

Kết quả. Với cả hai thay đổi, CIRAG chuyển từ chỗ kém IRCoT sang hơn IRCoT (Bảng 1). Riêng phép kiểm mới đóng góp 3,40 điểm ($p = 0{,}0005$), với 20 câu được sửa đúng so với 3 câu bị làm sai. Khi chúng tôi đổi mô hình nền sang Qwen3-30B-A3B, cải tiến vẫn cùng chiều nhưng nhỏ hơn và chưa đạt ý nghĩa thống kê (55,40 lên 57,00 EM, $p = 0{,}12$). Đáng chú ý là trên cả hai mô hình nền, CIRAG sau cải tiến đều hơn IRCoT đúng 1,4 điểm, còn trước thì bằng hoặc kém.

Hạn chế của cải tiến. Nó không vượt được biến thể luôn đọc mức đoạn ở Bảng 2: 60,40 so với 61,20, $p = 0{,}56$.

9 Loại trừ bốn cách giải thích

Mỗi cách giải thích được kiểm bằng một thí nghiệm chỉ đổi đúng một biến. Phép tái lập ở §6 đã loại cách thứ nhất, lỗi cài đặt. Với cách thứ hai, prompt tiếng Việt do chúng tôi viết còn prompt tiếng Anh là của nhóm tác giả, nên đây là biến gây nhiễu có thật. Chúng tôi chạy lại cả 500 câu bằng prompt gốc và thu được 57,40 EM so với 57,00, phân bố mức ngữ cảnh gần như không đổi.

Cách thứ ba đòi so từng khâu giữa hai bộ dữ liệu trên cùng mô hình nền. Recall truy hồi, tỷ lệ tích hợp giữ được ít nhất một triple, và tỷ lệ sinh được truy vấn kế tiếp đều lệch dưới năm điểm.

Cách thứ tư cần một đính chính, vì kết quả đổi dấu tuỳ mốc so sánh. Nếu lấy NativeRAG làm mốc thì khoảng cách của CIRAG co từ 8,8 xuống 1,8 điểm khi mô hình nền mạnh lên, nhưng NativeRAG đọc thẳng cả mười đoạn nên hưởng lợi bất thường từ mô hình mạnh, và chỗ co lại phản ánh NativeRAG khá lên chứ không phải CIRAG kém đi. Còn nếu lấy IRCoT làm mốc thì đổi mô hình nền chỉ dịch chuyển khoảng cách 0,8 điểm, so với 15,2 điểm do đổi bộ dữ liệu.

Điều còn lại. Sau khi loại cả bốn, phần chênh lệch duy nhất đạt ý nghĩa thống kê nằm ở loại câu hỏi: CIRAG hơn IRCoT 4,5 điểm ở nhóm câu đúng/sai ($n = 156$, $p = 0{,}15$) nhưng kém 4,9 điểm ở nhóm câu mở ($n = 344$, $p = 0{,}031$). Câu mở đòi hỏi tái tạo nguyên văn một cụm từ, đúng chỗ nén ngữ cảnh thành triple gây thiệt vì triple đã lược bỏ cách diễn đạt gốc.

10 Kết luận

Lợi thế 14 điểm của CIRAG không xuất hiện trên ViMQA, và nguyên nhân nằm ở chính điều kiện dừng của phương pháp. Điều rút ra được vượt ra ngoài CIRAG: một điều kiện dừng suy từ hành vi của mô hình chỉ đáng tin chừng nào mô hình còn bộc lộ hành vi đó, mà mô hình nền càng mạnh thì càng ít bộc lộ. Một điều kiện đặt lên chính bằng chứng không để chỗ cho kiểu lỗi âm thầm đó.

Hạn chế

Kết luận chính dựa trên hai bộ dữ liệu, mà phép tái lập trên 2WikiMQA chỉ chạy 100 câu hỏi với kho ngữ liệu 770 đoạn, nhỏ hơn hẳn 1.000 câu của bài báo gốc. Thiết lập nhỏ hơn khiến truy hồi dễ hơn, nên phép tái lập chỉ có giá trị một chiều: nó bác bỏ được nghi ngờ cài đặt sai, nhưng không chứng minh được bản cài đặt tương đương hoàn toàn.

Việc loại trừ vai trò của mô hình nền dựa trên hai mô hình, đủ để thấy đóng góp của yếu tố này nhỏ so với yếu tố bộ dữ liệu, nhưng chưa đủ để mô tả quan hệ theo năng lực. Cuối cùng, hai trường hợp EM cho điểm 0 dù đúng (§5) ảnh hưởng tới cả ba phương pháp: riêng 99 câu có đáp án tham chiếu dài đã chiếm 89 trong 215 câu sai của CIRAG.

References

Jinyuan Fang, Zaiqiao Meng, and Craig MacDonald. 2024. TRACE the evidence: Constructing knowledge-grounded reasoning chains for retrieval-augmented generation. In *Findings of the Association for Computational Linguistics: EMNLP*, pages 8472–8494.

Jinyuan Fang, Zaiqiao Meng, and Craig Macdonald. 2025. KiRAG: Knowledge-driven iterative retriever for enhancing retrieval-augmented generation. *arXiv preprint arXiv:2502.18397*.

Bernal Jimenez Gutierrez, Yiheng Shu, Yu Gu, Michihiro Yasunaga, and Yu Su. 2024. HippoRAG: Neurobiologically inspired long-term memory for large language models. In *Advances in Neural Information Processing Systems*, volume 37, pages 59532–59569.

Walter Kintsch and Teun A. Van Dijk. 1978. Toward a model of text comprehension and production. *Psychological Review*, 85(5):363.

Khang Le, Hien Nguyen, Tung Le Thanh, and Minh Nguyen. 2022. VIMQA: A Vietnamese dataset for advanced reasoning and explainable multi-hop question answering. In *Proceedings of the Thirteenth Language Resources and Evaluation Conference*, pages 6521–6529. European Language Resources Association.

Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, et al. 2020. Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems*, 33:9459–9474.

Ofir Press, Muru Zhang, Sewon Min, Ludwig Schmidt, Noah A. Smith, and Mike Lewis. 2023. Measuring and narrowing the compositionality gap in language models. In *Findings of the Association for Computational Linguistics: EMNLP 2023*, pages 5687–5711.

Harsh Trivedi, Niranjan Balasubramanian, Tushar Khot, and Ashish Sabharwal. 2023. Interleaving retrieval with chain-of-thought reasoning for knowledge-intensive multi-step questions. In *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics*, pages 10014–10037.

Zili Wei, Xiaocui Yang, Yilin Wang, Zihan Wang, Weidong Bao, Shi Feng, Daling Wang, and Yifei Zhang. 2026. CIRAG: Construction-integration retrieval and adaptive generation for multi-hop question answering. *arXiv preprint arXiv:2601.06799*.

Zhilin Yang, Peng Qi, Saizheng Zhang, Yoshua Bengio, William W. Cohen, Ruslan Salakhutdinov, and Christopher D. Manning. 2018. HotpotQA: A dataset for diverse, explainable multi-hop question answering. In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*, pages 2369–2380.